20 octobre : covariance et matrice de Pearson

Comment deux variables varient-elles ensemble ?

- Partir du nuage, construire une mesure, comprendre sa géométrie.
- Distinguer description, estimation et approximation linéaire.
- Calculer puis défendre une interprétation sur les données de Beijing.

Bilan de la séance de 4 heures : jusqu'à la matrice de Pearson. TP du 5 octobre à finaliser.

Notebook anglais ↗ · parcours et objectifs

Variables aléatoires et valeurs observées

Le modèle est défini sur $(\Omega, \mathcal{F}, \mathbb{P})$: issues possibles, événements et probabilités. E désigne l'espérance dans ce modèle ; aucune théorie de la mesure supplémentaire n'est nécessaire ici.

- (X, Y) est un couple aléatoire générique, de loi jointe P_{XY}.
- Pour n ≥ 2 fixé, (X_i, Y_i) désigne le i-ème couple aléatoire, i = 1,…,n. Les hypothèses sur ces couples seront précisées avant la preuve.

Une réalisation ω_0 de l'expérience fournit les nombres observés :

$$x_i = X_i(\omega_0), \quad y_i = Y_i(\omega_0)$$

Le fichier contient les valeurs minuscules. Répéter l'expérience pourrait produire d'autres valeurs ; les variables aléatoires décrivent cette variabilité.

La covariance de population : le paramètre visé

On suppose $E[X^2] < \infty$ et $E[Y^2] < \infty$. Les moyennes μ_X, μ_Y et la covariance σ_{XY} sont des paramètres déterministes, généralement inconnus.

$$\mu_X = E[X], \quad \mu_Y = E[Y]$$

$$\mathrm{Var}(X) = E\left[(X - \mu_X)^2\right]$$

$$\sigma_{XY} = \mathrm{Cov}(X, Y) = E[(X - \mu_X)(Y - \mu_Y)]$$

- Les écarts de même signe donnent un produit positif ; les signes opposés, un produit négatif. Pour Y = X, on retrouve la variance.

À discuter : La moyenne de population μ_X varie-t-elle quand on tire un autre échantillon ?

Rappels : les règles utilisées dans la preuve

U,V,W sont ici des variables aléatoires de moments d'ordre deux finis ; a,b sont des constantes.

- **Linéarité de l'espérance** :

$$E[aU + bV] = aE[U] + bE[V]$$

- **Bilinéarité de la covariance** (aussi dans le second argument) :

$$\mathrm{Cov}(aU + bV, W) = a\,\mathrm{Cov}(U, W) + b\,\mathrm{Cov}(V, W)$$

- **Indépendance** de U,V : $E[UV] = E[U]E[V]$, donc covariance nulle.

La réciproque est fausse. Pour les moyennes d'échantillon, nous appliquerons les deux premières règles aux sommes des X_i et des Y_j.

Indépendance : factoriser l'espérance du produit

Cas fini : U et V sont indépendantes ; u et v désignent leurs valeurs possibles.

1. Factoriser les probabilités. L'indépendance signifie :

$$\mathbb{P}(U = u, V = v) = \mathbb{P}(U = u)\mathbb{P}(V = v)$$

2. Calculer l'espérance du produit et séparer les sommes.

$$\begin{aligned} E[UV] &= \sum_u \sum_v uv\mathbb{P}(U = u, V = v) \\ &= \sum_u \sum_v u\mathbb{P}(U = u)\, v\mathbb{P}(V = v) \\ &= \left(\sum_u u\mathbb{P}(U = u)\right)\left(\sum_v v\mathbb{P}(V = v)\right) \\ &= E[U]E[V] \end{aligned}$$

Chaque facteur ne dépend que d'un indice de somme. Cette factorisation vaut aussi pour des variables indépendantes de moments d'ordre deux finis.

Indépendance : annuler la covariance

3. Développer les produits centrés. Posons $\mu_U = E[U]$ et $\mu_V = E[V]$: ce sont des constantes.

$$\begin{aligned}\mathrm{Cov}(U,V) &= E[(U-\mu_U)(V-\mu_V)] \\ &= E[UV - \mu_V U - \mu_U V + \mu_U\mu_V] \\ &= E[UV] - \mu_V E[U] - \mu_U E[V] + \mu_U\mu_V \\ &= E[UV] - \mu_U\mu_V\end{aligned}$$

Sous indépendance, l'étape 2 donne $E[UV] = \mu_U\mu_V$, donc :

$$\mathrm{Cov}(U,V) = \mu_U\mu_V - \mu_U\mu_V = 0$$

Les produits centrés peuvent être positifs ou négatifs ; leur espérance s'annule. L'identité $\mathrm{Cov}(U,V) = E[UV] - E[U]E[V]$ reste vraie sans indépendance. La covariance nulle, à elle seule, ne prouve pas l'indépendance.

I.i.d. : indépendance des couples, pas dans le couple

Les n couples sont indépendants et de même loi jointe P_{XY}, avec moments d'ordre deux finis. À indice égal : $\mathrm{Cov}(X_i, Y_i) = \sigma_{XY}$.

Si i ≠ j, l'indépendance des couples donne :

$$E[X_i Y_j] = E[X_i]E[Y_j]$$

$$\mathrm{Cov}(X_i, Y_j) = 0$$

Cette hypothèse n'impose pas l'indépendance de X_i et Y_i.

C_n regroupe les covariances entre indices i,j :

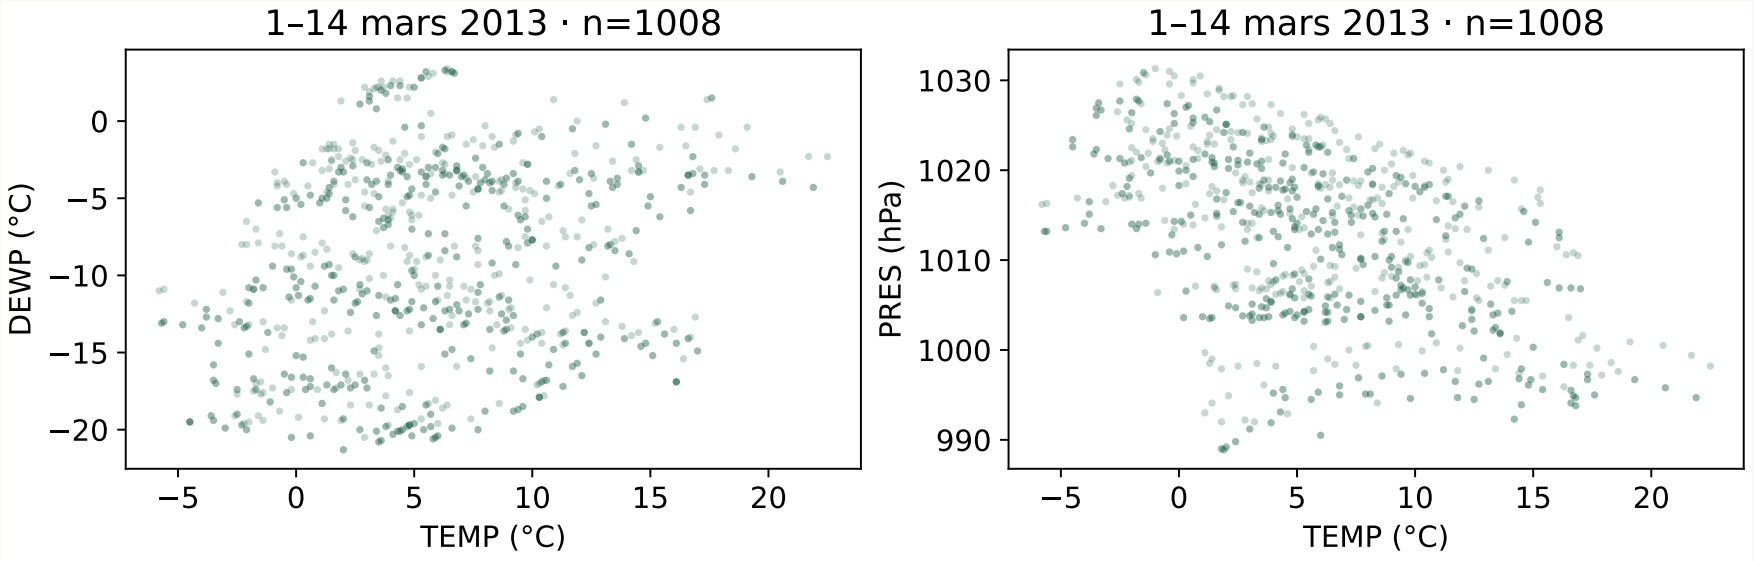
$$C_n = \begin{pmatrix} \sigma_{XY} & 0 & \dots & 0 \\ 0 & \sigma_{XY} & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \sigma_{XY} \end{pmatrix}$$

n termes diagonaux ; les autres sont nuls. Ici les axes indexent les observations.

À discuter : Température et point de rosée mesurés ensemble doivent-ils être indépendants ?

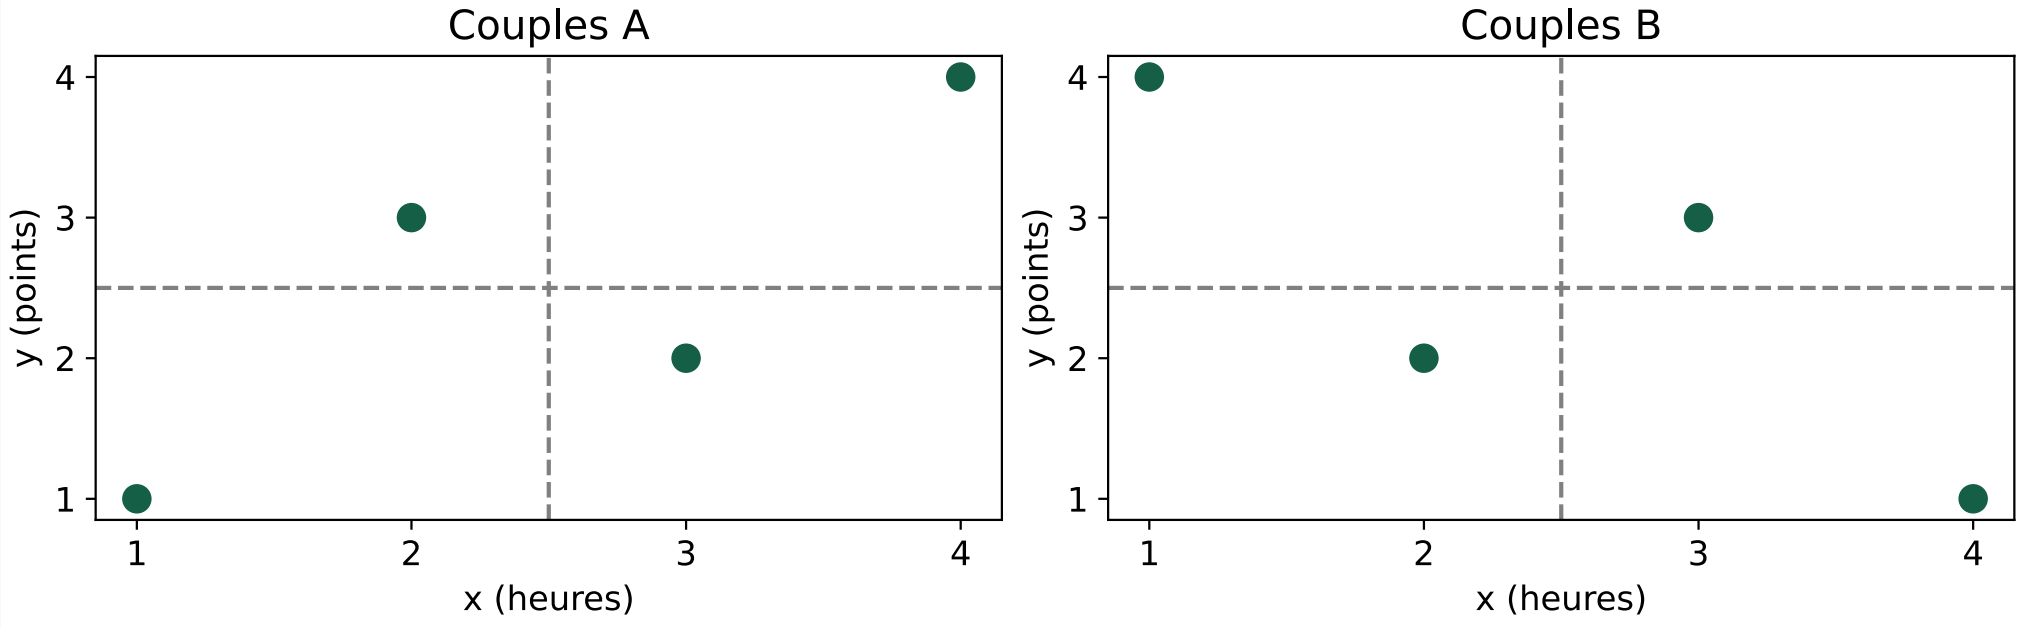
Du dernier TP à une nouvelle question

Une station-heure = une station observée à une heure ; n = nombre de paires complètes. TEMP : température ; DEWP : température du point de rosée (condensation), en °C ; PRES : pression, en hPa.



À discuter : Que voit-on que deux histogrammes ne montrent pas ? Même station-heure pour les deux coordonnées ; valeurs manquantes retirées par paire.

Mêmes distributions, associations opposées



À discuter : Chaque distribution décrit les valeurs d'une variable seule. Ici, leurs valeurs restent les mêmes, mais leur appariement change : les grandes valeurs vont-elles ensemble ?

Définir la somme centrée avant de la calculer

Les moyennes d'échantillon sont aléatoires ; leurs réalisations sont les moyennes numériques :

$$\overline{X} = \frac{\sum_{i=1}^{n} X_i}{n}, \quad \overline{Y} = \frac{\sum_{i=1}^{n} Y_i}{n}$$

$$\overline{x} = \overline{X}\,(\omega_0), \quad \overline{y} = \overline{Y}\,(\omega_0)$$

Nous appelons Q_{XY} la somme aléatoire des produits centrés, et q_{xy} sa valeur observée :

$$Q_{XY} = \sum_{i=1}^{n} \big(X_i - \overline{X}\big)\big(Y_i - \overline{Y}\big)$$

$$q_{xy} = Q_{XY}\,(\omega_0) = \sum_{i=1}^{n} (x_i - \overline{x})(y_i - \overline{y})$$

$\overline{X}$ est une statistique ; μ_X est un paramètre. Même si $E\left[\overline{X}\right] = \mu_X$ sous le modèle de même loi, ces objets ne sont pas identiques.

Quatre couples : une réalisation numérique

n = 4 ; x_i en heures, y_i en points. Les vecteurs x,y contiennent les observations ; $\mathbf{1}$ contient n uns ; x_c, y_c désignent les vecteurs centrés.

$$x = (1, 2, 3, 4), \quad y = (1, 3, 2, 4), \quad \overline{x} = \overline{y} = 2.5$$

$$x_c = x - \overline{x}\mathbf{1} = (-1.5, -0.5, 0.5, 1.5)$$

$$y_c = y - \overline{y}\mathbf{1} = (-1.5, 0.5, -0.5, 1.5)$$

$$q_{xy} = 2.25 - 0.25 - 0.25 + 2.25 = 4$$

Deux valeurs à distinguer : $c_n = \frac{q_{xy}}{n} = 1$ et $s_{xy} = \frac{q_{xy}}{n-1} = \frac{4}{3}$. Nous allons expliquer les deux diviseurs.

Notebook anglais ↗ · § 2 · calculer avant de vérifier

Paramètre, covariance empirique, estimateur

- **Population** : σ_{XY} est la covariance de la loi P_{XY}.
- **Loi empirique** : chaque couple observé reçoit le poids 1/n. Sa covariance exacte est $c_n = \frac{q_{xy}}{n}$.

Un **estimateur** est une règle appliquée à l'échantillon aléatoire. Une **estimation** est sa valeur après observation :

$$S_{XY} = \frac{Q_{XY}}{n-1}, \quad s_{xy} = S_{XY}(\omega_0) = \frac{q_{xy}}{n-1}$$

« Sans biais » signifiera $E[S_{XY}] = \sigma_{XY}$ sous des hypothèses précises. Cela n'affirme jamais $s_{xy} = \sigma_{XY}$ pour le fichier observé.

Pourquoi n−1 ? Une identité algébrique

On manipule les variables aléatoires. Le centrage par une moyenne d'échantillon s'écrit :

$$X_i - \overline{X} = (X_i - \mu_X) - \left(\overline{X} - \mu_X\right)$$

$$\sum_{i=1}^{n}(X_i - \mu_X) = n\left(\overline{X} - \mu_X\right)$$

Même égalité pour Y. Dans le produit développé, chacun des deux termes croisés retire $n\left(\overline{X} - \mu_X\right)\left(\overline{Y} - \mu_Y\right)$; le terme constant en remet une copie. D'où :

$$Q_{XY} = \sum_{i=1}^{n}(X_i - \mu_X)(Y_i - \mu_Y) - n\left(\overline{X} - \mu_X\right)\left(\overline{Y} - \mu_Y\right)$$

Cette identité ne requiert aucune indépendance. Le notebook développe explicitement les quatre termes.

Les n termes diagonaux donnent la correction

Par bilinéarité, la covariance des moyennes est la somme des covariances croisées, divisée par n² :

$$\mathrm{Cov}\left(\overline{X}, \overline{Y}\right) = \frac{1}{n^2} \sum_{i=1}^{n} \sum_{j=1}^{n} \mathrm{Cov}(X_i, Y_j) = \frac{n\sigma_{XY}}{n^2} = \frac{\sigma_{XY}}{n}$$

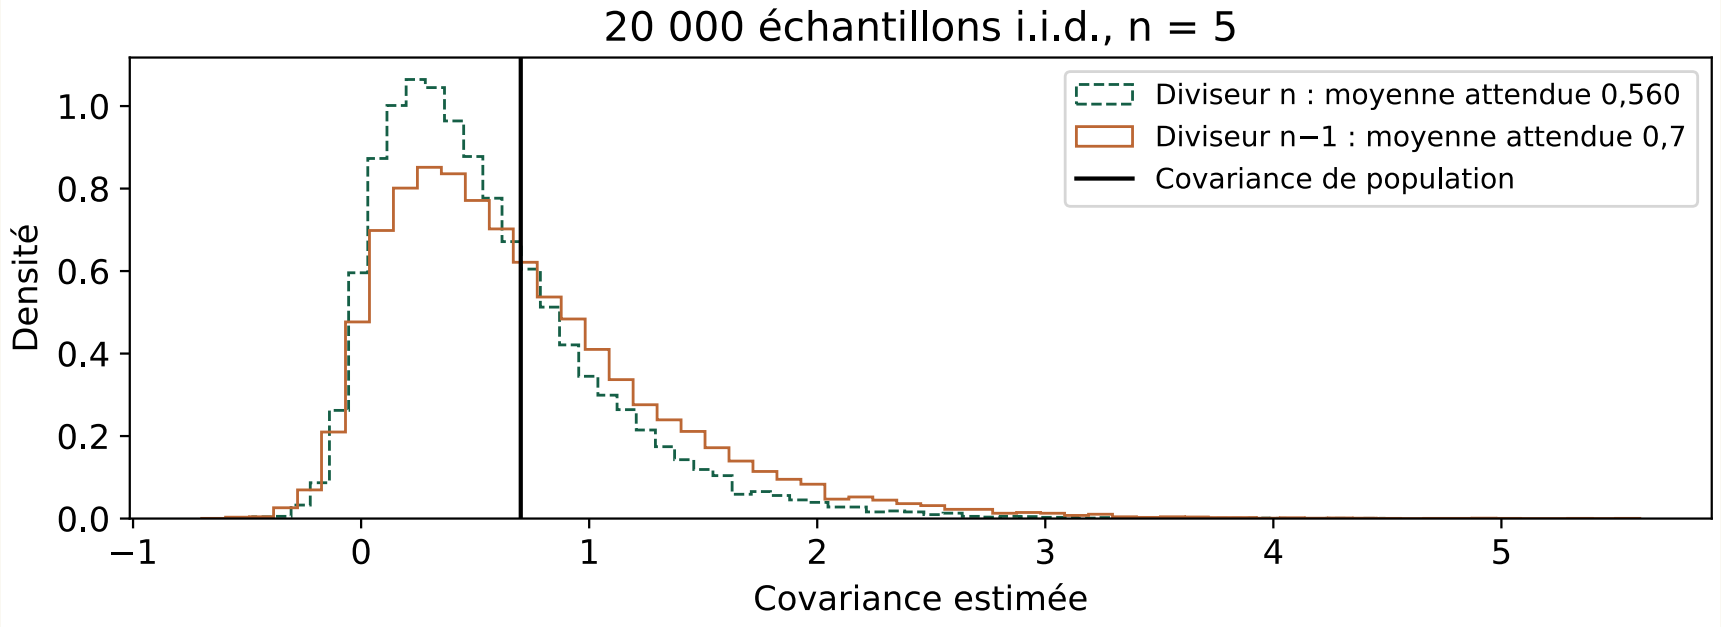
On prend ensuite l'espérance de l'identité précédente :

$$E[Q_{XY}] = n\sigma_{XY} - n\frac{\sigma_{XY}}{n} = (n-1)\sigma_{XY}$$

$$E[S_{XY}] = \sigma_{XY}, \quad E\left[\frac{Q_{XY}}{n}\right] = \frac{n-1}{n}\sigma_{XY}$$

Pour Y = X : $S_{XX} = \sum_i \frac{\left(X_i - \overline{X}\right)^2}{n-1}$ et $E[S_{XX}] = \mathrm{Var}(X)$. C'est la variance corrigée, avec la même preuve.

Sans biais ne veut pas dire exact



Chaque tirage donne une estimation différente. La moyenne simulée approche une espérance ; elle ne constitue pas une preuve. Le notebook compare n = 5, 20, 100 pour covariance et variance.

Le diviseur n contracte l’espérance vers zéro : pour une covariance négative, le biais est positif.

Notebook anglais ↗ · § 3 · simulation reproductible et dépendance des heures de Beijing

Les unités empêchent une comparaison directe

Transformation affine : multiplier par une constante puis ajouter un décalage. a,c : facteurs d'échelle ; b,d : décalages. Exemple : °F = 1,8 × °C + 32.

$$\mathrm{Cov}(aX + b, cY + d) = ac\,\mathrm{Cov}(X, Y)$$

$$\mathrm{Cov}(60X, Y) = 60\,\mathrm{Cov}(X, Y)$$

- Le nuage décrit le même phénomène après conversion des unités.
- La covariance numérique change pourtant d'un facteur 60.

À discuter : Par quelle quantité de même unité peut-on diviser ?

Centrer et réduire : fixer une moyenne et une variance

L'écart-type d'échantillon s_x (et de même s_y) est la racine de la variance corrigée :

$$s_x = \sqrt{\frac{\sum_{i=1}^{n} (x_i - \overline{x})^2}{n-1}}$$

- Centrer : $x_c = x - \overline{x}\mathbf{1}$; la moyenne devient zéro.
- Réduire : $\frac{x_c}{s_x}$; la variance corrigée devient un, si $s_x > 0$.

Pour les quatre couples : $s_x = s_y = \sqrt{\frac{5}{3}}$. Diviser par une échelle n'efface pas une relation courbe.

Longueur, produit scalaire et autres normalisations

L'espace $\mathbb{R}^n$ contient les vecteurs de n nombres. Pour x,y dans cet espace, T désigne la transposition.

$$x^T y = \sum_{i=1}^{n} x_i y_i, \quad \|x\| = \sqrt{x^T x}$$

- Produit scalaire nul : vecteurs orthogonaux, donc à angle droit.
- Normalisation euclidienne : $\frac{x}{\|x\|}$ a longueur un si $x \neq 0$.
- Min-max : $\frac{x - \min(x)}{\max(x) - \min(x)}$ place les valeurs entre 0 et 1, si l'étendue est positive.

Centrage-réduction, longueur unitaire et min-max répondent à des objectifs différents.

Pearson : retirer les unités de la covariance

Nous notons ρ_{XY} la corrélation de population. $\sigma_X = \sqrt{\mathrm{Var}(X)} > 0$ et $\sigma_Y = \sqrt{\mathrm{Var}(Y)} > 0$: écarts-types de population.

$$\rho_{XY} = \frac{\mathrm{Cov}(X, Y)}{\sigma_X \sigma_Y}$$

Les variables centrées-réduites, notées Z_X, Z_Y, sont :

$$Z_X = \frac{X - \mu_X}{\sigma_X}, \quad Z_Y = \frac{Y - \mu_Y}{\sigma_Y}$$

$$\mathrm{Cov}(Z_X, Z_Y) = \rho_{XY}$$

- Population : ρ. Échantillon : $r_{xy} = \frac{s_{xy}}{s_x s_y}$.

Écarts-types strictement positifs et même diviseur. Le résultat sans biais démontré pour la covariance ne se transmet pas automatiquement au coefficient de Pearson.

Dans l’échantillon, Pearson est un cosinus

θ est l’angle entre les deux vecteurs centrés non nuls.

$$x_c = x - \overline{x}\mathbf{1}, \quad y_c = y - \overline{y}\mathbf{1}$$

$$r_{xy} = \frac{\frac{x_c^T y_c}{n-1}}{\sqrt{\frac{x_c^T x_c}{n-1}}\sqrt{\frac{y_c^T y_c}{n-1}}}$$

$$r_{xy} = \frac{x_c^T y_c}{\|x_c\|\|y_c\|} = \cos(\theta)$$

- Angle entre deux colonnes centrées de $\mathbb{R}^n$, pas entre deux points du nuage.

À discuter : Pourquoi faut-il centrer avant de normaliser la longueur ?

Le centrage enlève une dimension

Pour les vecteurs observés x,y, I_n est l'identité et $\mathbf{1}$ le vecteur de n uns. H retire la moyenne de chaque colonne :

$$H = I_n - \frac{1}{n}\mathbf{1}\mathbf{1}^T, \quad x_c = Hx, \quad y_c = Hy$$

$$H^T = H, \quad H^2 = H, \quad H\mathbf{1} = 0$$

$\mathbf{1}^\perp$ est l'espace des vecteurs de somme nulle. Il a dimension n−1 : la dernière coordonnée est imposée par les précédentes. H est sa projection orthogonale.

$$\mathrm{rang}(H) = \mathrm{tr}(H) = n - 1$$

La trace tr est la somme des coefficients diagonaux. Cette géométrie explique la contrainte ; l'égalité d'espérances exige encore les hypothèses sur les couples. Preuve détaillée en lecture complémentaire.

Bornes et cas d’égalité : Cauchy–Schwarz

$$\left|x_c^T y_c\right| \leq \|x_c\|\|y_c\| \rightarrow -1 \leq r_{xy} \leq 1$$

- Égalité si et seulement si les deux vecteurs non nuls sont proportionnels.

$$y_c = a x_c \quad \rightarrow \quad y_i = a x_i + b$$

- Orthogonalité : $r_{xy} = 0$. Alignement : $r_{xy} = 1$ ou $r_{xy} = -1$.

Échelle positive : même corrélation. Une seule échelle négative : signe inversé.

Pourquoi la covariance parle-t-elle de linéarité ?

U, V désignent les variables aléatoires centrées ci-dessous. L^2 est l'espace des variables W telles que $E[W^2] < \infty$; ici, la longueur vient de l'espérance du carré.

$$\mathrm{Cov}(X, aX + b) = a\,\mathrm{Var}(X)$$

$$U = X - E[X], \quad V = Y - E[Y]$$

$$\langle U, V \rangle = E[UV], \quad \|U\|^2 = \mathrm{Var}(X)$$

$\langle U, V \rangle$ est leur produit scalaire. On identifie les variables égales presque sûrement, c'est-à-dire avec probabilité un : une longueur nulle signifie alors le même élément.

La meilleure approximation par une droite

a : pente candidate ; J(a) : erreur quadratique moyenne ; $a^\star$: pente qui minimise J. Le résidu est l'écart $V - a^\star U$.

$$J(a) = E\big[(V - aU)^2\big] = E\big[V^2\big] - 2aE[UV] + a^2 E\big[U^2\big]$$

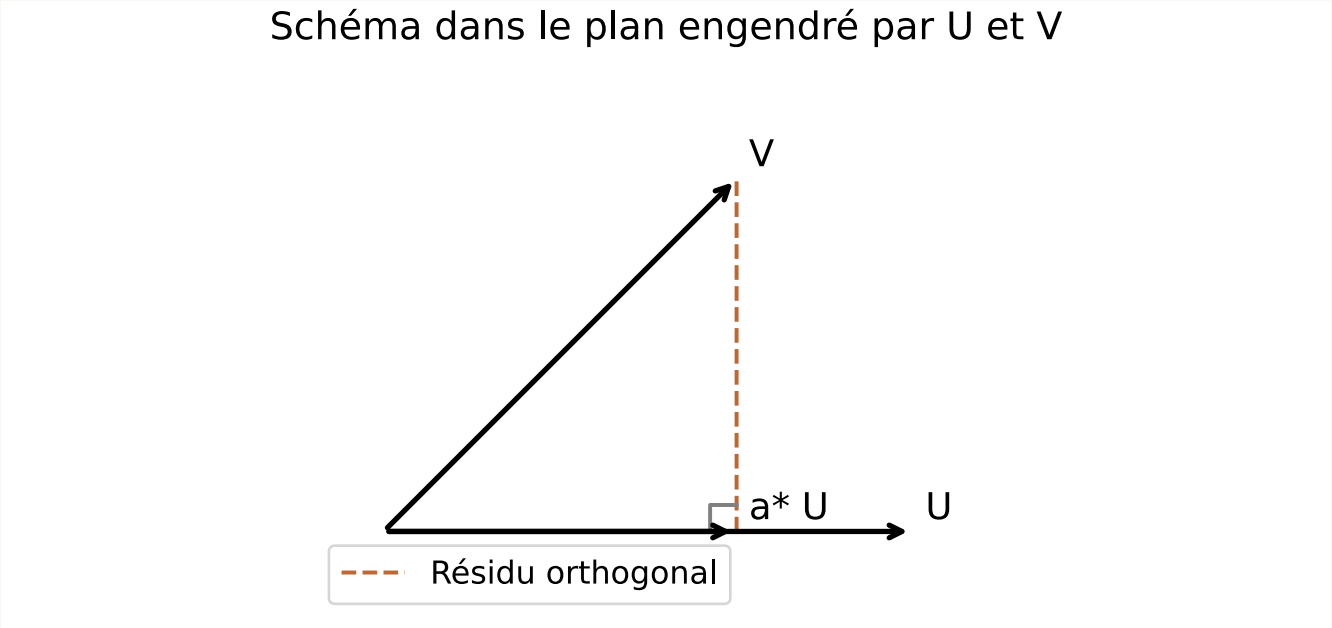
$$J'(a) = 0 \quad \rightarrow \quad a^\star = \frac{\mathrm{Cov}(X, Y)}{\mathrm{Var}(X)}$$

$$E[U(V - a^\star U)] = 0$$

- Variance de X positive : minimum unique ; résidu orthogonal à U.

Prédicteur affine : $\mu_Y + a^{\star(X-\mu_X)}$. La meilleure droite ne suit pas nécessairement la moyenne de Y à chaque valeur de X, si celle-ci est courbe.

La projection explique la formule



- Covariance nulle : aucune composante de V dans la direction U.

À discuter : Peut-il rester une dépendance dans une direction non linéaire ?

Une dépendance parfaite avec Pearson nul

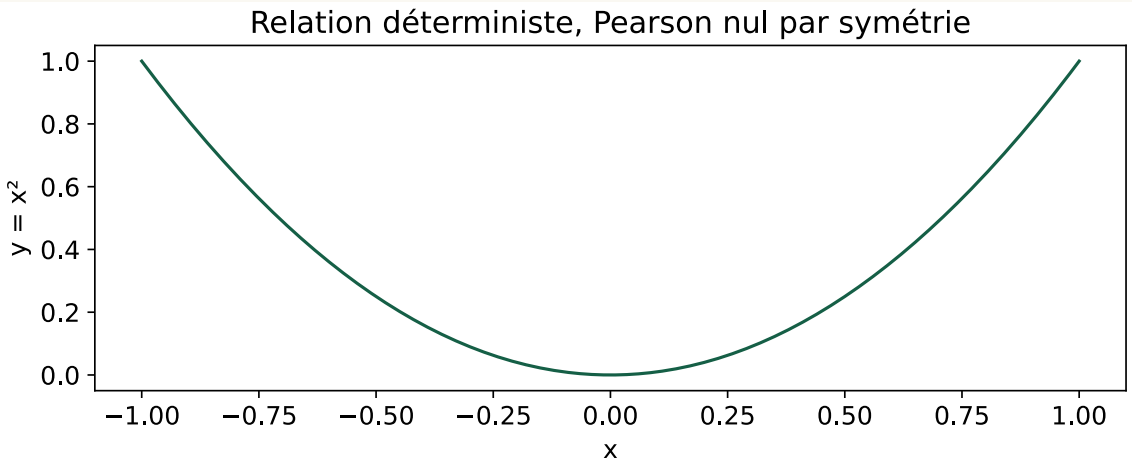
$\mathcal{U}(-1,1)$ désigne la loi uniforme : dans cet intervalle, deux sous-intervalles de même longueur ont la même probabilité.

$$X \sim \mathcal{U}(-1,1), \quad Y = X^2$$

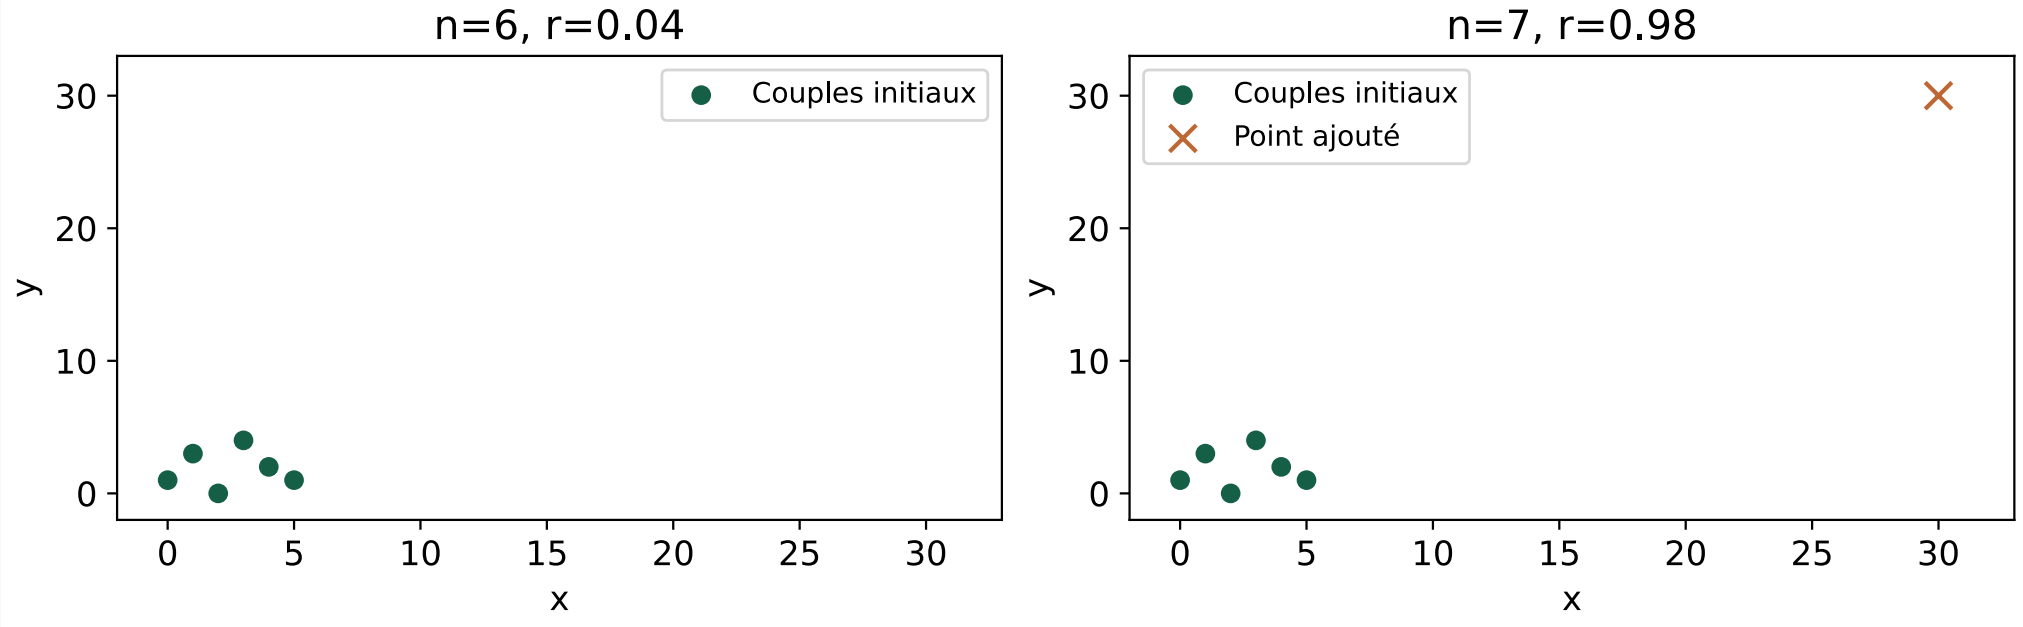
$$E[X] = E[X^3] = 0$$

$$\mathrm{Cov}(X,Y) = 0$$

Variances : 1/3 et 4/45. Les événements $|X| \leq \frac{1}{2}$ et $Y \leq \frac{1}{4}$ coïncident. Leur probabilité et celle de leur intersection valent 1/2 ; l'indépendance donnerait 1/4.



Un point peut dominer le coefficient



- Vérifier l'origine du point et comparer le coefficient avec et sans lui avant de justifier une exclusion.

Corrélation : association linéaire descriptive ; aucune preuve de causalité.

Du produit d’écarts à la projection

Centrage → produit scalaire → covariance → angle de Pearson → projection linéaire

- Une preuve : pourquoi $E[S_{XY}] = \sigma_{XY}$ sous les hypothèses i.i.d. ?
- Une limite : pourquoi une courbe peut-elle avoir Pearson nul ?
- Une trace écrite : paire, station, période, n, unités, nuage, conclusion bornée.

Ces outils permettent maintenant de terminer la covariance et Pearson dans votre TP du 5 octobre. Garder une paire, son effectif et ses unités dans votre conclusion.

Une table, deux espaces géométriques

n observations, p variables numériques ; A_{ij} est la valeur observée de la variable j à la ligne i. A est une matrice de nombres fixés : sa majuscule désigne ici une matrice, pas une variable aléatoire.

$$A \in \mathbb{R}^{n \times p}, \quad A = \begin{pmatrix} 1 & 2 \\ 3 & 4 \\ 5 & 6 \end{pmatrix}, \quad n = 3, \quad p = 2$$

- Chaque ligne est un point de $\mathbb{R}^p$: ici (1,2), (3,4), (5,6).
- Chaque colonne est un vecteur de $\mathbb{R}^n$: ici (1,3,5) et (2,4,6).

Chaque ligne complète contient toutes les variables choisies. Comme en séance 1, on retire les lignes incomplètes sans remplacer leurs valeurs manquantes.

Centrer est une projection orthogonale

I_n : identité ; $\mathbf{1}$: n uns ; T : transposition ; $\overline{a}$: vecteur des p moyennes. P garde la partie constante ; H la retire.

$$P = \frac{\mathbf{1}\mathbf{1}^T}{n}, \quad H = I_n - P, \quad A_c = HA = A - \mathbf{1}\overline{a}^T$$

$$P^T = P, \quad P^2 = P \quad \rightarrow \quad H^T = H, \quad H^2 = H$$

Dans notre table : $\overline{a} = (3, 4)^T$; lignes centrées (−2,−2), (0,0), (2,2).

Projection orthogonale : on retire une partie perpendiculaire au résultat. Ici, chaque colonne centrée a une somme nulle ; elle est orthogonale au vecteur constant. En code : `Ac = A - A.mean(axis=0)`.

La covariance : un produit entre colonnes

j et k indexent les variables (1,…,p) ; i les lignes (1,…,n), avec n > 1. S_{jk} est leur covariance ; s_j est l'écart-type corrigé de la colonne j.

$$S = \frac{1}{n-1} A_c^T A_c = \frac{1}{n-1} A^T H A \in \mathbb{R}^{p \times p}$$

$$S_{jk} = \frac{1}{n-1} \sum_{i=1}^{n} (A_{ij} - \overline{a}_j)(A_{ik} - \overline{a}_k)$$

- Diagonale : variances $S_{jj} = s_j^2$. Hors diagonale : covariances.

Dans notre exemple, $S = \begin{pmatrix} 4 & 4 \\ 4 & 4 \end{pmatrix}$. Les deux colonnes centrées sont identiques.

La matrice observée et le paramètre de population

$\boldsymbol{W} = \left(W_1, \ldots, W_p\right)^T$ est un vecteur aléatoire générique ; $\boldsymbol{W}_i$ est le i-ème vecteur d'un échantillon i.i.d. Sa réalisation fournit la ligne i de A. $\mu = E[\boldsymbol{W}]$ est le vecteur des moyennes de population. La matrice de population Γ contient $\Gamma_{jk} = \mathrm{Cov}\left(W_j, W_k\right)$. La moyenne aléatoire et l'estimateur matriciel sont :

$$\overline{\boldsymbol{W}} = \frac{\sum_{i=1}^{n} \boldsymbol{W}_i}{n}$$

$$\hat{\Gamma}_n = \frac{1}{n-1} \sum_{i=1}^{n} \left(\boldsymbol{W}_i - \overline{\boldsymbol{W}}\right)\left(\boldsymbol{W}_i - \overline{\boldsymbol{W}}\right)^T$$

$$S = \hat{\Gamma}_n\left(\omega_0\right), \quad E\left[\hat{\Gamma}_n\right] = \Gamma$$

La dernière égalité utilise l'hypothèse i.i.d. et les moments d'ordre deux. Les identités de centrage, de Gram et d'ACP sur A restent des identités sur la table observée, sans cette hypothèse.

Gram, rang et noyau : trois rappels utiles

- **Gram** : matrice des produits scalaires entre des vecteurs ; ici les colonnes centrées de A, divisées par n−1.
- **Rang** : nombre de colonnes linéairement indépendantes. Notre exemple a deux colonnes identiques après centrage, donc un rang égal à 1.
- **Noyau** : ensemble des vecteurs envoyés sur zéro ; noté $\ker$. Ici $A_c \begin{pmatrix} 1 \\ -1 \end{pmatrix} = 0$.

Une matrice carrée de rang incomplet est dite singulière : elle n’est pas inversible. Des colonnes colinéaires (proportionnelles) peuvent produire cette situation.

Pourquoi symétrique et semi-définie positive ?

Pour tout vecteur v de p coefficients, $\|A_c v\|^2$ est la somme des carrés de ses n coordonnées. « Semi-définie positive » signifie $v^T S v \geq 0$ pour tout v.

$$S^T = S, \quad v^T S v = \frac{\|A_c v\|^2}{n-1} \geq 0$$

$$\ker(S) = \ker(A_c), \quad \operatorname{rang}(S) = \operatorname{rang}(A_c) \leq \min(p, n-1)$$

- La norme nulle équivaut à $A_c v = 0$: mêmes noyaux, donc mêmes rangs. Le centrage impose une contrainte de somme nulle.

Retirer des lignes différentes pour chaque paire peut détruire la structure de Gram : cette preuve exige une seule table complète.

La corrélation choisit l’échelle de chaque axe

diag construit une matrice diagonale. D contient les variances ; $D^{-\frac{1}{2}}$ a pour diagonale $\frac{1}{s_1}, \ldots, \frac{1}{s_p}$. On suppose chaque $s_j > 0$.

$$D = \mathrm{diag}\left(s_1^2, \ldots, s_p^2\right), \quad A_z = A_c D^{-\frac{1}{2}}$$

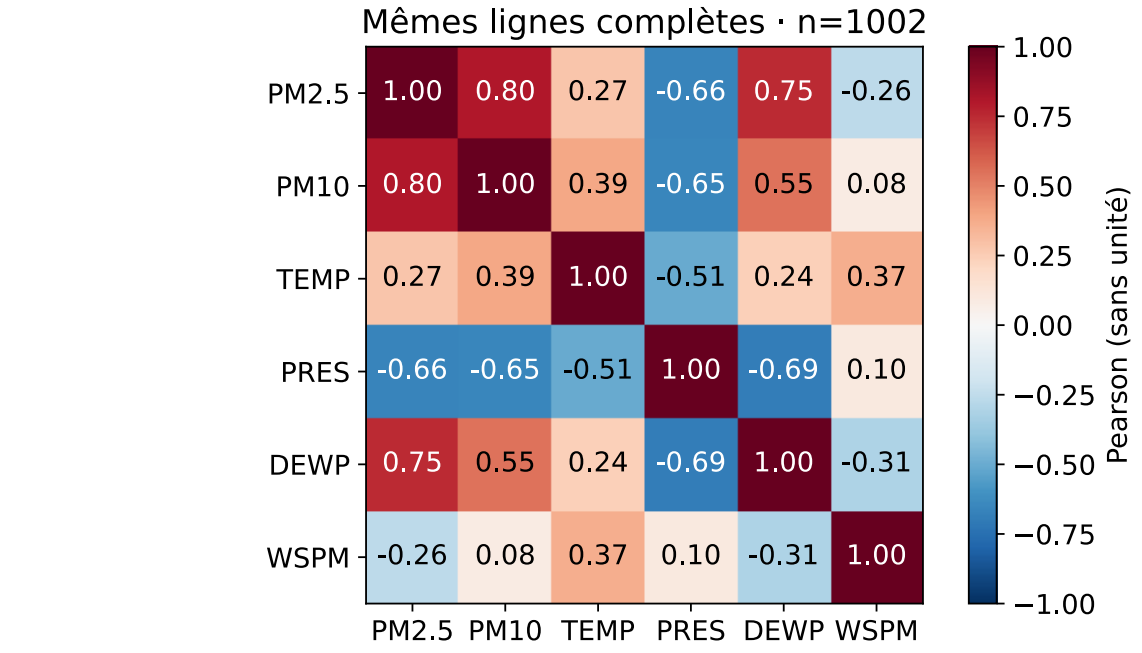
$$R = D^{-\frac{1}{2}} S D^{-\frac{1}{2}} = \frac{1}{n-1} A_z^T A_z$$

- R est la matrice de Pearson : chaque colonne de A_z a variance un.
- Sur S : unités originales. Sur R : distances entre observations mesurées en écarts-types. C’est un changement de métrique, c’est-à-dire de règle de mesure des distances.

À discuter : Une mesure peu fiable doit-elle recevoir le même poids après réduction ?

Beijing : lire la matrice avec ses nuages

Une carte de couleurs (heatmap) associe une couleur à chaque coefficient. PM2.5 et PM10 : particules (µg/m³) ; TEMP et DEWP : température et point de rosée (°C) ; PRES : pression (hPa) ; WSPM : vent (m/s).



1–14 mars 2013 ; 1 002 station-heures complètes. Lire une case avec son nuage : la couleur ne montre ni courbure ni causalité.

Travail à finaliser : le TP du 5 octobre

Reprendre votre notebook Statistical Exploration déjà commencé. Garder vos calculs, votre audit et vos graphiques.

- **Parties 5–7.** Nuages appariés, covariance explicite et Pearson sur les mêmes paires ; vérifier avec pandas.
- **Matrice et effectifs.** Terminer la carte des coefficients et le tableau des effectifs. Comparer suppression par paire et mêmes lignes complètes.
- **Interpréter.** Donner unités, signe, n et une limite ; vérifier l'effet d'un changement d'unité positif.

Compléter la sélection de la partie 9 et le Results existant. Ce travail était à finaliser ; la séance ne garantit pas que chaque étudiant l'ait terminé.

Reprendre le TP du 5 octobre ↗

Prochaine étape : le 2 novembre

- **Acquis introduits.** Les matrices S et R décrivent les relations entre toutes les variables sur une table commune.
- **Nouvelle question.** Peut-on résumer ces variables par quelques nouvelles coordonnées qui conservent beaucoup de variance ?
- **ACP et SVD.** L'analyse en composantes principales choisit les directions ; la décomposition en valeurs singulières les calcule.
- **Le 9 novembre : régression.** Désigner une réponse à estimer ; distinguer cet objectif de la reconstruction des entrées.

Le 2 novembre : théorie et TP ACP, puis la question d'une réponse à estimer. La régression et les premiers pas en apprentissage supervisé sont prévus le 9 novembre.