2 novembre : ACP, directions et reconstruction

Le 20 octobre, nous sommes arrivés à la matrice de Pearson. Aujourd’hui : que faire de cette information ?

- **Question.** Résumer plusieurs mesures par quelques nouvelles directions de grande variance.
- **Théorie.** Projection, contrainte de longueur, valeurs propres, scores et SVD.
- **TP.** Calculer et interpréter des composantes sur les observations de Beijing.

2 heures, dont 45 minutes de TP. La régression sera étudiée le 9 novembre ; aujourd’hui, nous en poserons la question.

Notebook anglais ↗ · séance du 2 novembre

Rappel du 20 octobre : partir de S ou de R

A : table observée ; A_c : colonnes centrées ; S : covariance. s_j : écart-type de la colonne j ; D : diagonale des variances ; A_z : table centrée-réduite.

$$S = \frac{A_c^T A_c}{n-1}, \quad D = \mathrm{diag}\left(s_1^2, ..., s_p^2\right)$$

$$A_z = A_c D^{-\frac{1}{2}}, \quad R = \frac{A_z^T A_z}{n-1}$$

- Les mêmes lignes complètes sont utilisées pour toutes les variables. R est la matrice de Pearson, déjà introduite le 20 octobre.
- Sur S, les échelles originales comptent. Sur R, chaque variable a variance un. Le choix définit ce qu'on veut préserver.

A et ses matrices sont des nombres observés. Les preuves et l'exemple de matrice sont dans le support du 20 octobre.

La nouvelle question : combiner les variables

- **La matrice décrit des paires.** Une case de R résume une relation linéaire entre deux mesures.
- **L'ACP cherche des axes.** Peut-on représenter chaque station-heure par deux ou trois coordonnées, plutôt que six ?
- **Critère.** Conserver le plus possible de dispersion du nuage, mesurée par la variance des coordonnées projetées.
- **Choix.** Covariance : préserver les échelles choisies. Corrélation : comparer des variations mesurées en écarts-types.

L'ACP est descriptive : aucune variable à prédire n'est désignée. Un axe de grande variance n'est pas automatiquement utile pour une future réponse.

Des axes qui combinent les mesures physiques

La direction $v = \left(w_1, \ldots, w_p\right)^T$ possède un coefficient w_j par variable. Sur la table centrée-réduite, le score z_i de la ligne i est :

$$z_i = \sum_{j=1}^{p} \left(A_z\right)_{ij} w_j$$

- Chaque coefficient indique comment sa variable entre dans cette nouvelle coordonnée. Un score appartient à une observation ; la direction contient p coefficients.
- La composante ne correspond pas nécessairement à un capteur physique. Elle peut résumer un motif commun ou un contraste entre plusieurs mesures.
- Après centrage-réduction, les scores sont sans unité physique ; leur interprétation demande de lire les coefficients avec les variables originales.

Nommer prudemment un axe après inspection. Son signe peut être inversé sans changer le sous-espace ni la reconstruction ; ce n’est pas une preuve de causalité.

Deux variables : une somme et un contraste

Reprenons les quatre couples déjà calculés : leurs variables centrées-réduites ont une corrélation de 0,8. Leur matrice est :

$$R = \begin{pmatrix} 1 & 0.8 \\ 0.8 & 1 \end{pmatrix}, \quad v_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \quad v_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ -1 \end{pmatrix}$$

Si $x_{z,i}, y_{z,i}$ sont les deux valeurs centrées-réduites de la ligne i :

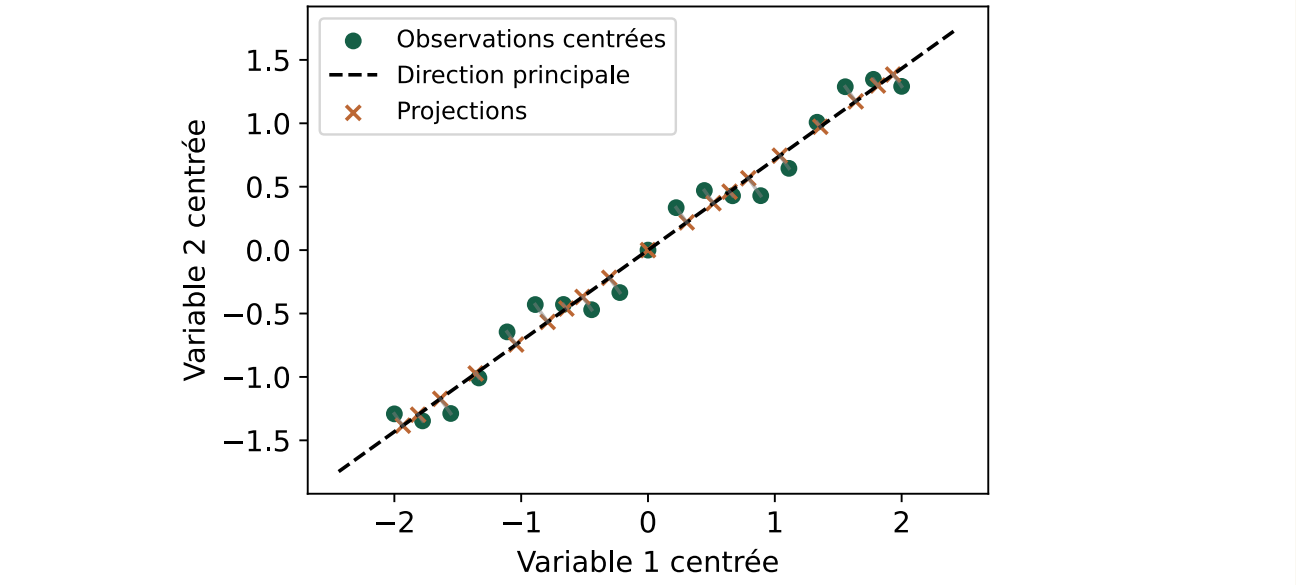
$$z_{i,1} = \frac{x_{z,i} + y_{z,i}}{\sqrt{2}}, \quad z_{i,2} = \frac{x_{z,i} - y_{z,i}}{\sqrt{2}}$$

- Première coordonnée : variation commune ; variance 1,8, soit 90 % du total 2. Seconde : contraste ; variance 0,2.

Ces axes combinent les deux variables. Le choix des directions de variance maximale sera justifié par le problème d'optimisation.

Choisir une direction de grande dispersion

Une direction principale est un axe sur lequel le nuage projeté conserve le plus de variance. La projection orthogonale tombe perpendiculairement sur cet axe.



À discuter : Pourquoi imposer une longueur unitaire à la direction ?

L’ACP est un problème d’optimisation

v : direction de p coefficients, de longueur un ; z : n coordonnées projetées, appelées scores. s_z^2 : variance corrigée de ces scores ; leur moyenne est nulle.

$$v^T v = 1, \quad z = A_c v \in \mathbb{R}^n$$

$$s_z^2 = \frac{z^T z}{n-1} = v^T S v, \quad \max_{v^T v = 1} v^T S v$$

- Ici, variance signifie variance d’échantillon des scores observés. Les valeurs propres calculées décrivent cette table ; sans contrainte, multiplier v augmenterait cette variance arbitrairement.

Pour v = (1,0), les scores sont la première colonne centrée, de variance S_{11}. Dans le TP, remplacer A_c, S par A_z, R : même raisonnement après centrage-réduction.

Le Lagrangien : objectif et contrainte

L'objectif est $f(v) = v^T S v$; la contrainte est $g(v) = v^T v - 1 = 0$. Le scalaire λ est un multiplicateur inconnu.

$$L(v, \lambda) = v^T S v - \lambda(v^T v - 1)$$

∇_v regroupe les dérivées suivant les coordonnées de v. Comme S est symétrique :

$$\nabla_v L = 2Sv - 2\lambda v = 0 \quad \rightarrow \quad Sv = \lambda v$$

$$\frac{\partial L}{\partial \lambda} = -(v^T v - 1) = 0$$

- Un vecteur propre non nul vérifie $Sv = \lambda v$; λ est sa valeur propre. Pour une direction unitaire, $v^T S v = \lambda$ est la variance projetée.

Ces équations donnent des candidats. Il reste à choisir celui qui réalise le maximum ; on ne maximise pas L conjointement en v et λ.

La plus grande valeur propre donne le maximum

Le théorème spectral donne, pour S symétrique, une base orthonormée (v_j) de vecteurs propres : longueurs un, produits scalaires nuls entre directions distinctes. Ordonnons $\lambda_1 \geq \ldots \geq \lambda_p$. Les coordonnées de v dans cette base sont $\alpha_j = v_j^T v$. Si v est unitaire :

$$v = \sum_j \alpha_j v_j, \quad \sum_j \alpha_j^2 = 1, \quad v^T S v = \sum_j \lambda_j \alpha_j^2 \leq \lambda_1$$

- La borne est atteinte pour $v = v_1$. La variance sur ce premier axe est donc λ_1.
- Pour le deuxième axe, imposer en plus l'orthogonalité au premier ; poursuivre pour les axes suivants.

Dans l'exemple somme / contraste : 1,8 est la plus grande variance projetée ; 0,2 est celle de la direction orthogonale.

Directions et scores : ne pas les confondre

j,k indexent les directions, de 1 à p. La part de variance compare une variance projetée à la somme des p variances, supposée positive.

$$v_j \in \mathbb{R}^p, \quad z_j = A_c v_j \in \mathbb{R}^n$$

$$s^2_{z_j} = \lambda_j, \quad \frac{z_j^T z_k}{n-1} = 0 \quad (j \neq k)$$

$$\text{part de variance}_j = \frac{\lambda_j}{\sum_{\ell=1}^{p} \lambda_\ell}$$

- Directions orthogonales ; scores non corrélés, pas forcément indépendants.

Changer le signe d’un axe change le signe des scores, pas la reconstruction. Si plusieurs valeurs propres sont égales, leurs axes peuvent tourner dans le même sous-espace.

Le TP : reconstruire les valeurs centrées-réduites

Choisir k directions parmi p. V_k les regroupe en colonnes ; Z_k regroupe les scores. $\hat{A}_z$ est la table centrée-réduite reconstruite.

$$V_k = (v_1, ..., v_k), \quad Z_k = A_z V_k, \quad \hat{A}_z = Z_k V_k^T$$

- La reconstruction revient aux p variables : elle possède n lignes et p colonnes, même avec k = 2.
- L'erreur de Frobenius au carré additionne les carrés des erreurs de toutes les cellules. La mesurer ici sur les valeurs centrées-réduites.

Retour facultatif aux mesures physiques : $\overline{a}_j$ est la moyenne d'origine et s_j son écart-type.

$$\hat{A}_{ij} = \overline{a}_j + s_j \left(\hat{A}_z\right)_{ij}$$

La reconstruction n'utilise aucune réponse à prédire. Les premières directions minimisent cette erreur pour un nombre k de coordonnées fixé.

SVD économique : définir les facteurs et dimensions

La décomposition en valeurs singulières sépare directions, échelles et scores. $q = \min(n, p)$; $\Sigma = \mathrm{diag}(\sigma_1, ..., \sigma_q)$ avec $\sigma_1 \geq ... \geq \sigma_q \geq 0$.

$$A_c = U\Sigma V^T$$

$$U \in \mathbb{R}^{n \times q}, \quad \Sigma \in \mathbb{R}^{q \times q}, \quad V \in \mathbb{R}^{p \times q}$$

$$U^T U = I_q, \quad V^T V = I_q$$

Les colonnes u_j de U et v_j de V sont orthonormées ; I_q est l'identité de taille q. σ_j est une valeur singulière, distincte de l'écart-type s_j.

À discuter : Quelle est la dimension du score $A_c v_j = \sigma_j u_j$?

La SVD calcule directement l'ACP

$$S = \frac{1}{n-1} V \Sigma^T U^T U \Sigma V^T$$

$$S = V \frac{\Sigma^T \Sigma}{n-1} V^T$$

$$\lambda_j = \frac{\sigma_j^2}{n-1}, \quad j = 1, ..., q$$

- Les scores sont les colonnes de $U\Sigma$. Les directions sont celles de V. Si q < p, les p−q autres valeurs propres de S sont nulles.
- Même calcul sur A_z pour l'ACP centrée-réduite.

Tronquer la SVD signifie conserver les k plus grandes valeurs singulières et leurs directions : on retrouve la reconstruction précédente.

Trois contrôles pour construire le calcul

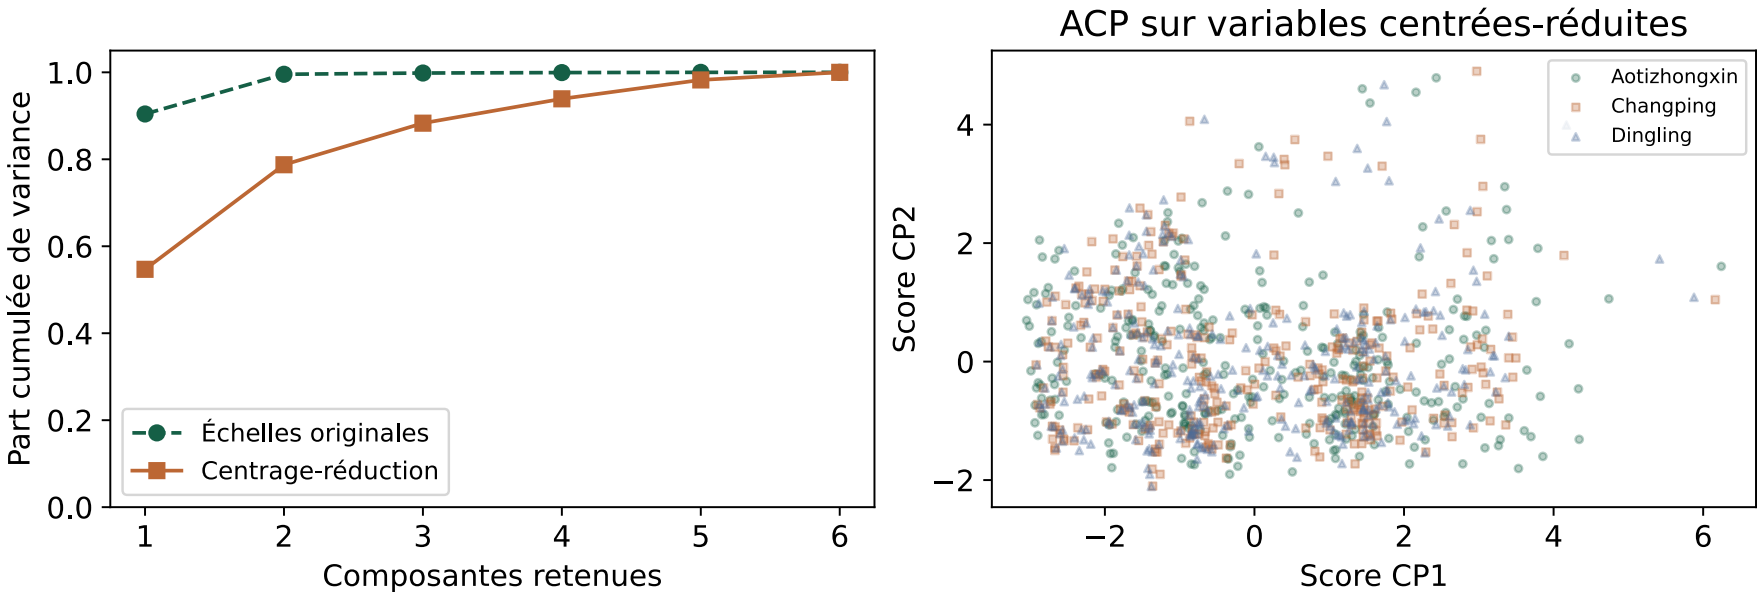
- **Table.** Après centrage-réduction : mêmes n lignes et p colonnes ; moyennes proches de zéro, variances proches de un.
- **Projection.** Une direction contient p coefficients ; une composante donne n scores. Vérifier les dimensions avant le produit.
- **Reconstruction.** Retrouver n lignes et p colonnes ; comparer l'erreur avec le retour aux moyennes.

NumPy renvoie les directions en lignes dans `Vt`. Les calculs restent à construire dans le TP ; les indices repliables aident à vérifier les étapes.

Notebook anglais ↗ · trois points de contrôle du TP

Beijing : l’échelle modifie les composantes

CP1 et CP2 : première et deuxième composantes principales. Leurs scores sont les coordonnées de chaque station-heure sur les deux axes retenus.



À discuter : Que préserve le graphique de gauche ? Que ne prouve pas celui de droite ?

TP ACP : calculer, interpréter, comparer

- **Préparer.** Garder les mêmes observations complètes ; justifier covariance ou corrélation avant le calcul.
- **Calculer.** Directions, scores et parts de variance ; comparer directions de p coefficients et scores de n observations.
- **Lire.** Identifier les variables qui contribuent à un axe ; expliquer ce que signifie un score élevé pour une station-heure.
- **Comparer.** Reconstruire avec deux puis trois composantes sur les mêmes données centrées-réduites. Mesurer le gain de variance et la baisse d’erreur.

45 minutes, de la minute 60 à 105. Calculs à construire ; trois contrôles et des indices facultatifs. Garder cinq minutes pour conclure.

Notebook anglais ↗ · TP guidé du 2 novembre

Bilan : ce que votre ACP permet de dire

- **Choix.** Expliquer pourquoi le TP utilise la matrice R plutôt que S. Les unités et la fiabilité des mesures comptent dans cette décision.
- **Résultat.** Interpréter un axe avec ses coefficients et une station-heure ; comparer variance et erreur pour deux puis trois composantes.
- **Limite.** Une variance bien reconstruite décrit les entrées ; elle ne garantit pas qu'une quantité particulière soit bien estimée.

À discuter : Quelle information perd-on en gardant seulement deux composantes ?

Donner les dimensions d'une direction, de ses scores et de la table reconstruite. Relier l'erreur à la variance écartée.

Semaine suivante : régression et apprentissage

- **Nouvelle question.** Peut-on estimer PM2.5 avec PM10 et les mesures météorologiques disponibles à la même heure ? PM2.5 devient la réponse.
- **Régression, le 9 novembre.** Introduire une droite, ses coefficients et ses résidus, puis plusieurs variables explicatives.

L'apprentissage supervisé utilise des exemples avec une réponse connue pour ajuster une règle ; on l'évalue ensuite sur d'autres observations.

- **Validation.** Ajuster transformations et coefficients sur l'apprentissage seulement ; comparer à une référence simple.

Aucun ajustement de régression n'est requis aujourd'hui. Les preuves et l'expérience chronologique de Beijing sont disponibles comme préparation du 9 novembre.